GUIDE FORMATEUR

# L'IA generative pour les Data Engineers

Deroule pedagogique detaille, timing, consignes de TP et elements de reponse

Client : BFORBANK

Lieu : Presentiel a Paris La Defense

Du 19 au 23 octobre 2026 — 5 jours / 35 heures

*Document reserve au formateur — non destine a etre remis aux participants*

# Sommaire


Fiche formation 3

Grille horaire des 5 journees 5

Jour 1 — Fondamentaux de l'IA generative 6

Jour 2 — Manipulation de LLM avec Python et LangChain 10

Jour 3 — Generation et evaluation de donnees synthetiques 14

Jour 4 — Securisation, industrialisation et cas d'usage avances 18

Jour 5 — Projet de fin : pipeline intelligent 22

Annexe A — Quiz de revision (corrige) 26

Annexe B — Modalites pedagogiques et evaluation 27

# Fiche formation

**Intitule :** L'IA generative pour les Data Engineers

**Duree :** 5 jours / 35 heures

**Client :** BFORBANK | **Lieu :** Presentiel a Paris La Defense

**Dates :** Du 19 au 23 octobre 2026

**Horaires :** Jour 1 : 9h15 (installation formateur) - 9h30-13h00 / 14h00-17h30 | Jours 2 a 5 : 9h00-12h30 / 13h30-17h00

## Prerequis apprenants

- Bonne maitrise de Python (fonctions, structures de donnees, environnements virtuels)
- Connaissance des architectures de donnees (pipelines ETL/ELT, bases relationnelles, formats semi-structures)
- Connaissance des API REST (methodes HTTP, authentification, format JSON)
- A l'aise avec au moins un outil cloud (stockage, calcul ou orchestration)

## Public cible

- Data Engineers
- Data Architects
- Developpeurs backend en charge de flux de donnees
- Ingenieurs data en charge des pipelines de traitement de donnees

## Objectifs pedagogiques

- Comprendre les concepts fondamentaux de l'IA generative
- Identifier les cas d'usage pertinents pour les Data Engineers
- Manipuler des modeles de langage comme GPT dans des flux de traitement
- Generer et valider des donnees synthetiques pour enrichir les jeux de donnees
- Automatiser certaines taches grace a des API d'IA generative
- Evaluer les risques ethiques et de securite lies a ces usages

## Materiel et prerequis techniques

- Un ordinateur par participant avec un IDE Python (VS Code recommande) et Python 3.10 ou superieur
- Acces internet stable autorisant les appels vers les API OpenAI / Anthropic (a valider en amont avec la DSI BFORBANK)
- Cle(s) API OpenAI et/ou Anthropic fournies par le formateur ou l'organisme, selon la politique de securite BFORBANK
- Environnement Python avec les bibliotheques openai, langchain, pydantic, jsonschema, faker (requirements.txt fourni en amont)

- Acces a un depot Git pour recuperer les squelettes de TP et deposer le projet fil rouge du Jour 5
- Aucune donnee reelle ou de production BFORBANK n'est utilisee : tous les TP s'appuient sur des jeux de donnees fictifs

# Grille horaire des 5 journees

| Jour | Contenu | Duree |
|---|---|---|
| Jour 1 | Fondamentaux de l'IA generative | 7h |
| Jour 2 | Manipulation de LLM avec Python et LangChain | 7h |
| Jour 3 | Generation et evaluation de donnees synthetiques | 7h |
| Jour 4 | Securisation, industrialisation et cas d'usage avances | 7h |
| Jour 5 | Projet de fin : pipeline intelligent | 7h |
| | **Total** | **35h** |

Horaires quotidiens : Jour 1 : 9h15 (installation formateur) - 9h30-13h00 / 14h00-17h30 — Jours 2 a 5 : 9h00-12h30 / 13h30-17h00 (pause dejeuner ; prevoir une pause de 15 min par demi-journee).

JOUR 1

# Fondamentaux de l'IA generative

7 heures — 9h15 (installation formateur) - 9h30-13h00 / 14h00-17h30

## 1 Fondamentaux de l'IA generative

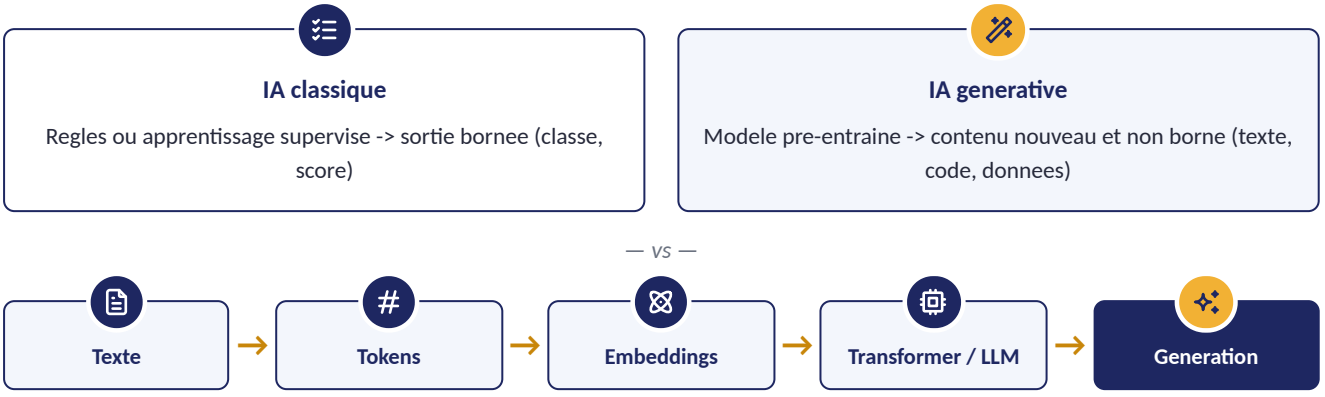
**Duree :** 3h30 | **Objectif :** Comprendre les concepts fondamentaux de l'IA generative et le principe de fonctionnement des LLM.

### Contenu

- Definition de l'IA generative : des modeles capables de produire du contenu inedit (texte, code, image, donnees) plutot que de seulement classer ou predire
- Historique resume : des reseaux de neurones classiques aux Transformers (2017), puis aux LLM grand public (GPT-3, ChatGPT en 2022)
- IA classique (regles, scoring, classification supervisee) versus IA generative (production de contenu nouveau par des modeles pre-entraines)
- Panorama des modeles existants : LLM texte (GPT, Claude, Llama, Mistral), generation d'image (DALL-E, Stable Diffusion), modeles multimodaux
- Principes de fonctionnement d'un LLM : tokenisation, embeddings, mecanisme d'attention, generation autoregressive token par token
- Notion de parametres, de fenetre de contexte (context window), et distinction fine-tuning versus prompt engineering
- Panorama des plateformes : Hugging Face (hub de modeles), OpenAI, Anthropic, Mistral AI, Google

SCHEMA

### IA classique vs IA generative, et pipeline d'un LLM




### Minutage indicatif

| Minutage | Sequence |
|---|---|
| 0-20 min | Accueil, tour de table, presentation du programme des 5 jours |

| | |
|---|---|
| 20-50 min | Definition, historique, IA classique vs IA generative |
| 50-90 min | Panorama des modeles (LLM texte, image, multimodaux) |
| 90-130 min | Fonctionnement d'un LLM : tokenisation, embeddings, attention |
| 130-145 min | Pause |
| 145-200 min | TP1 en autonomie sur Hugging Face |
| 200-210 min | Debriefing collectif |

**Point de vigilance formateur**
Verifier en amont que chaque poste a bien acces a huggingface.co (proxy/pare-feu BFORBANK). Le TP1 est volontairement exploratoire : l'objectif est la comprehension par la manipulation, pas la production d'un livrable.

TRAVAUX PRATIQUES N°1

### Exploration interactive de modeles sur Hugging Face

Duree indicative : 55 min

#### Consignes

- Se rendre sur huggingface.co et explorer le Hub de modeles en filtrant par tache (text-generation, text-classification)
- Comparer un modele de classification (ex. BERT fine-tune pour l'analyse de sentiment) et un LLM generatif (ex. Mistral-7B-Instruct, GPT-2) : nombre de parametres, carte modele (model card), tache visee
- Tester le widget d'inference en ligne sur 2 a 3 modeles et noter les differences de sortie obtenues
- Lister 3 criteres permettant de distinguer un LLM d'un modele classique de machine learning

### ✓ Elements de reponse — TP n°1

- Un modele classique produit une sortie bornee (une classe, un score) pour une tache unique pour laquelle il a ete entraine ou fine-tune
- Un LLM genere du texte libre, non borne, et peut etre reutilise pour de nombreuses taches via le prompt (few-shot, zero-shot) sans reentrainement
- Criteres de distinction attendus : taille du modele (nombre de parametres), nature de la sortie (classe vs texte libre), generalite (tache unique vs multi-taches par prompt), methode d'adaptation (fine-tuning vs prompting)

## 2 Usages et enjeux pour les Data Engineers

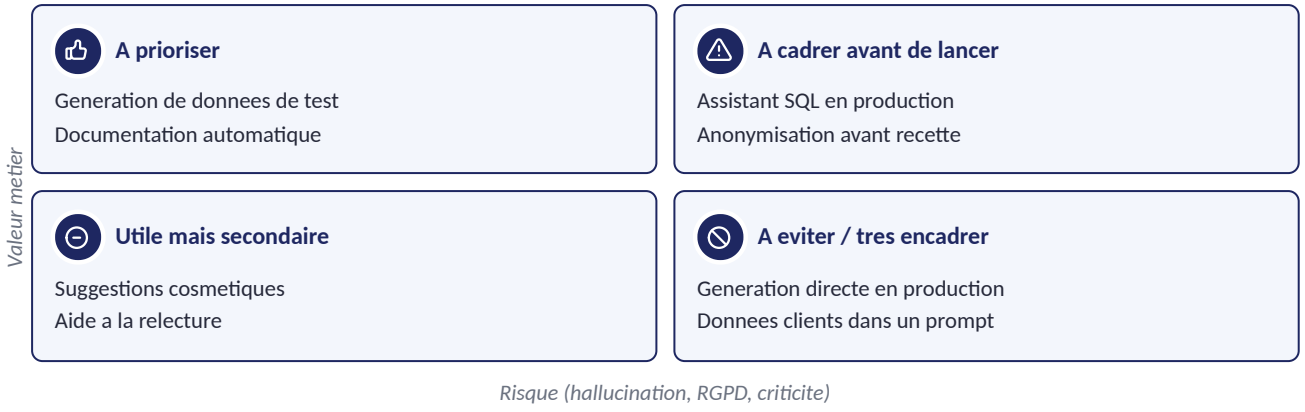
**Duree :** 3h30 | **Objectif :** Identifier les cas d'usage de l'IA generative pertinents pour un Data Engineer et les risques associes.

## Contenu

- Generation de donnees synthetiques : pourquoi (jeux de test, environnements de recette, equilibrage de classes rares) et comment (prompt structure, bibliotheques dediees)
- Anonymisation de donnees via IA : pseudonymisation assistee, generation de substituts realistes preservant la structure statistique des donnees d'origine
- Assistants intelligents pour les pipelines de donnees : generation de requetes SQL, documentation automatique de schemas, aide au debug de jobs ETL/ELT
- Risques : hallucinations (invention de faits ou de valeurs), biais herites des donnees d'entrainement, non-conformite RGPD (donnees personnelles dans les prompts, transfert hors UE)
- Panorama des cas d'usage prioritaires pour un Data Engineer : qualite de donnees, documentation, generation de tests, acceleration du developpement de pipelines

SCHEMA

### Prioriser un cas d'usage : valeur vs risque




### Minutage indicatif

| Minutage | Sequence |
|---|---|
| 0-30 min | Generation de donnees synthetiques : pourquoi et comment |
| 30-55 min | Anonymisation de donnees via IA |
| 55-85 min | Assistants intelligents pour les pipelines de donnees |
| 85-115 min | Risques : hallucinations, biais, RGPD |
| 115-130 min | Pause |
| 130-195 min | TP2 en binomes : etude de cas |
| 195-210 min | Restitution collective, bilan Jour 1 |

**Point de vigilance formateur**
Le TP2 se fait en binomes : constituer les binomes en amont pour melanger les profils (Data Engineer / Data Architect). Cadrer explicitement que les cas d'usage doivent rester generiques ou fictifs, sans reference a un systeme ou une donnee reelle BFORBANK.

TRAVAUX PRATIQUES N°2

## Etude de cas en binomes : quel cas d'usage prioriser ?

Duree indicative : 65 min

### Consignes

- En binome, choisir un pipeline ou un jeu de donnees representatif de votre contexte (ou un cas bancaire fictif propose par le formateur)
- Lister 3 cas d'usage possibles de l'IA generative sur ce pipeline (generation de donnees de test, documentation, detection d'anomalies...)
- Prioriser ces cas d'usage selon 2 criteres : valeur metier et risque (RGPD, hallucination, criticite du systeme)
- Restituer en 5 minutes maximum a l'ensemble du groupe

## ✓ Elements de reponse — TP n°2

- Grille de priorisation a utiliser en debrief : axe X = risque, axe Y = valeur metier ; privilegier les cas a forte valeur et faible risque (ex. generation de donnees de test)
- Exemples de cas d'usage bancaires attendus : generation de jeux de test anonymises pour un environnement de recette, documentation automatique de modeles de donnees, assistant de generation de requetes SQL pour les analystes
- Exemples a haut risque a identifier comme tels : generation directe de donnees envoyees en production, ou tout usage exposant des donnees clients reelles dans un prompt

**Bilan de fin de journee — Jour 1**

- Panorama de l'IA generative, de son historique et des grandes familles de modeles
- Cas d'usage et risques (hallucinations, biais, RGPD) pour un Data Engineer
- Premiere manipulation exploratoire de modeles sur Hugging Face

JOUR 2

# Manipulation de LLM avec Python et LangChain

7 heures — 9h00-12h30 / 13h30-17h00

## 3 Manipulation de LLM avec Python

**Duree :** 3h30 | **Objectif :** Maitriser les appels a une API d'IA generative depuis Python et la validation des reponses obtenues.

### Contenu

- Introduction a l'API OpenAI (ChatGPT) : modeles disponibles, endpoint de chat completions
- Authentification et gestion des cles API : variable d'environnement, jamais de cle en dur dans le code
- Parametres d'appel : messages system/user/assistant, temperature (creativite), max_tokens, top_p
- Notion de token : unite de decoupage du texte, impact direct sur le cout et la latence d'un appel
- Traitement des retours : structuration de la reponse, parsing JSON, validation du format attendu (pydantic, jsonschema)
- Integration dans un pipeline de donnees : appel LLM comme etape d'un pipeline Python, gestion des erreurs et des retries

SCHEMA

### Anatomie d'un appel API LLM dans un pipeline




### Minutage indicatif

| Minutage | Sequence |
|---|---|
| 0-20 min | Introduction a l'API OpenAI, modeles disponibles |
| 20-50 min | Authentification, gestion securisee des cles API |
| 50-90 min | Parametres d'appel : temperature, tokens, top_p |
| 90-120 min | Traitement des retours : parsing JSON, validation |
| 120-135 min | Pause |
| 135-195 min | TP3 en autonomie |
| 195-210 min | Correction collective |

**Point de vigilance formateur**
S'assurer avant la session que chaque participant dispose d'une cle API de test valide (fournie par le formateur) et que le reseau BFORBANK autorise les appels sortants vers l'API choisie. Prevoir un compte de secours en cas de quota atteint.

TRAVAUX PRATIQUES N°3

## Script Python pour interroger un LLM

Duree indicative : 60 min

### Consignes

- Ecrire un script Python qui envoie un prompt a l'API OpenAI (ou Anthropic) et affiche la reponse
- Parametrer la temperature et observer l'effet sur des appels repetes avec le meme prompt
- Demander une sortie structuree en JSON (ex. extraction d'entites d'un texte) et la parser avec le module json
- Tester volontairement un prompt ambigu ou incomplet et observer le comportement du modele

### ✓ Corrige propose — TP n°3

```
import os, json
from openai import OpenAI

client = OpenAI(api_key=os.environ["OPENAI_API_KEY"])  # jamais de cle en dur

reponse = client.chat.completions.create(
    model="gpt-4o-mini",
    temperature=0.2,
    messages=[
        {"role": "system", "content": "Tu extrais des entites et repond UNIQUEMENT en
JSON valide."},
        {"role": "user", "content": "Jean Dupont, ne le 12/05/1985, habite a Lyon."},
    ],
    response_format={"type": "json_object"},
)

donnees = json.loads(reponse.choices[0].message.content)
print(donnees)
```

- Avec une temperature basse (0-0.2), les appels repetes donnent des reponses quasi identiques ; avec une temperature elevee (0.8-1), les reponses varient davantage
- Que se passe-t-il si le prompt est mal formule : le modele produit tout de meme une reponse plausible mais non fiable (hallucination), ou une sortie qui ne respecte pas le format demande - d'ou la necessite de valider systematiquement la sortie (schema JSON, regeneration si echec)

# 4 LangChain pour orchestrer les LLM

**Duree :** 3h30 | **Objectif :** Orchestrer plusieurs appels a des LLM au sein d'un meme traitement, avec logging et observabilite.

## Contenu

- Introduction a LangChain : chaines (chains), composants (prompts, modeles, parsers), notion d'agent intelligent
- Prompts chaines : decomposer une tache complexe en plusieurs appels successifs
- Modeles hybrides : combiner un LLM puissant et un modele plus leger selon l'etape (routing, cout, latence)
- Memorisation et gestion de l'etat : conserver le contexte d'une conversation ou d'un pipeline multi-etapes
- Logging, monitoring et observabilite : tracer les appels, les prompts, les couts et les temps de reponse

SCHEMA

### Chaine LangChain simulant un ETL




*Logging a chaque etape : prompt envoye, reponse recue, duree, statut*

## Minutage indicatif

| Minutage | Sequence |
|---|---|
| 0-20 min | Introduction a LangChain, chaines et agents |
| 20-55 min | Prompts chaines et modeles hybrides |
| 55-85 min | Memorisation et gestion de l'etat |
| 85-110 min | Logging, monitoring et observabilite |
| 110-125 min | Pause |
| 125-190 min | TP4 en autonomie |
| 190-210 min | Correction, bilan Jour 2 |

**Point de vigilance formateur**
Le TP4 peut etre realise sans LangChain (chaine de prompts manuelle en Python) si l'installation pose probleme en salle - prevoir cette alternative en secours pour ne pas bloquer le groupe.

TRAVAUX PRATIQUES N°4

### Conception d'un assistant generatif simulant un ETL

Duree indicative : 75 min

## Consignes

- Concevoir avec LangChain (ou une chaine de prompts manuelle) un mini pipeline en 3 etapes : extraction d'un texte source, transformation/nettoyage assiste par LLM, generation d'un resume structure
- Ajouter un mecanisme de logging a chaque etape (prompt envoye, reponse recue, duree)
- Documenter les mecanismes de logging necessaires dans un contexte de production bancaire (tracabilite, audit)

## ✓ Elements de reponse — TP n°4

- Pipeline attendu : Extraction -> Prompt de nettoyage -> Prompt de resume structure -> sortie JSON validee, avec un log par etape
- Mecanismes de logging a integrer en contexte bancaire : horodatage, identifiant de requete/correlation, prompt et reponse (tronques ou masques si donnees sensibles), nombre de tokens et cout, statut succes/echec, conservation conforme a la politique de retention RGPD interne

**Bilan de fin de journee — Jour 2**

- Maitrise des appels a l'API d'un LLM depuis Python (parametres, parsing, validation)
- Orchestration de plusieurs appels avec LangChain : chaines, memoire, logging
- Bonne pratique : ne jamais exposer une cle d'API dans le code

JOUR 3

# Generation et evaluation de donnees synthetiques

7 heures — 9h00-12h30 / 13h30-17h00

## 5 Generation de donnees synthetiques

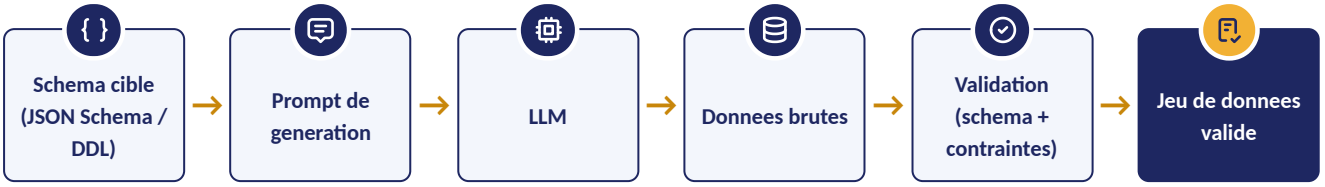
**Duree :** 3h30 | **Objectif :** Generer des donnees synthetiques conformes a un schema cible, dans le respect du RGPD.

### Contenu

- Cas d'usage de la generation : jeux de test, environnements de recette, anonymisation par substitution, equilibrage de classes rares en ML
- Methodes d'augmentation de donnees : generation par prompt structure, bibliotheques specialisees (Faker couple a un LLM, Synthetic Data Vault), generation conditionnelle
- Generation de schemas conformes : JSON Schema pour structurer la sortie, generation de DDL SQL conforme a un schema de donnees existant
- Validation des jeux synthetiques : coherence referentielle (cles etrangeres), respect des contraintes metier, absence de fuite de donnees reelles

SCHEMA

### Pipeline de generation de donnees synthetiques




### Minutage indicatif

| Minutage | Sequence |
|---|---|
| 0-25 min | Cas d'usage de la generation de donnees synthetiques |
| 25-60 min | Methodes d'augmentation de donnees |
| 60-95 min | Generation de schemas conformes (JSON Schema, SQL) |
| 95-120 min | Validation des jeux synthetiques |
| 120-135 min | Pause |
| 135-195 min | TP5 en autonomie |
| 195-210 min | Debriefing collectif |

**Point de vigilance formateur**
Rappeler explicitement avant le TP5 que le jeu de donnees RH genere doit etre entierement fictif : aucun nom, matricule ou donnee ne doit pouvoir correspondre a une personne reelle, y compris par coincidence plausible.

TRAVAUX PRATIQUES N°5

## Generation d'un dataset RH conforme RGPD

Duree indicative : 70 min

### Consignes

- Definir un schema de donnees RH (matricule, nom, prenom, date de naissance, poste, departement, date d'entree)
- Rediger un prompt de generation produisant N enregistrements respectant ce schema, avec des valeurs realistes mais entierement fictives
- Verifier la coherence des donnees generees (types, plages de valeurs, unicite du matricule)
- Documenter comment garantir qu'aucune donnee reelle ne s'est glissee dans le jeu genere

### ✓ Elements de reponse — TP n°5

- Prompt attendu : role + schema JSON explicite + contrainte 'toutes les personnes sont fictives, aucune ne doit correspondre a une personne reelle connue' + format de sortie en tableau JSON
- Comment garantir l'absence de donnees reelles : consigne explicite dans le prompt, controle croisé avec une liste noire de noms connus si disponible, relecture humaine par sondage, et interdiction de fournir au modele un exemple issu de donnees reelles en few-shot

## 6 Evaluation de la qualite de sortie

**Duree :** 3h30 | **Objectif :** Evaluer et fiabiliser la qualite d'une sortie generee par un LLM.

### Contenu

- Metriques qualite sur donnees generees : taux de conformite au schema, diversite (absence de duplication excessive), plausibilite statistique
- Outils de validation semantique : comparaison par embeddings, LLM-as-a-judge (faire evaluer une sortie par un second appel LLM)
- Detection d'hallucinations et filtres : recoupement avec une source de verite, filtrage par regles metier, score de confiance
- Post-traitement et enrichissement : nettoyage, normalisation, complement d'information par appel API ou jointure avec un referentiel

SCHEMA

### Chaine d'evaluation d'une sortie LLM




*Un enregistrement qui echoue le filtre est rejete ou regenere, jamais integre tel quel au jeu final*

### Minutage indicatif

| Minutage | Sequence |
|---|---|
| 0-25 min | Metriques qualite sur donnees generees |
| 25-55 min | Outils de validation semantique, LLM-as-a-judge |
| 55-85 min | Detection d'hallucinations et filtres |
| 85-105 min | Post-traitement et enrichissement |
| 105-120 min | Pause |
| 120-190 min | TP6 en autonomie |
| 190-210 min | Correction collective, bilan Jour 3 |

**Point de vigilance formateur**
Le TP6 reutilise le jeu de donnees du TP5 : prevoir un jeu de secours pre-genere pour les binomes qui n'auraient pas termine le TP5, afin de ne pas bloquer la progression.

TRAVAUX PRATIQUES N°6

## Evaluation qualite d'un output genere par GPT

Duree indicative : 70 min

### Consignes

- Reprendre le jeu de donnees RH genere au TP5 (ou un jeu fourni par le formateur)
- Definir 3 metriques de qualite : conformite de schema, plausibilite des valeurs, absence de doublons
- Identifier les enregistrements suspects (noms incoherents, valeurs hors plage, doublons)
- Proposer une action corrective pour chaque anomalie detectee

## ✓ Elements de reponse — TP n°6

- Exemples d'anomalies a repérer : prenom incoherent de type 'Xyz123', salaire negatif ou hors plage, date de naissance posterieure a la date d'entree, matricules dupliques

- Actions correctives attendues : ajout d'une regle de validation (regex, plage), regeneration ciblee de l'enregistrement fautif, filtre de rejet automatique avant integration dans le jeu final

**Bilan de fin de journee — Jour 3**

• Generation de donnees synthetiques conformes a un schema cible (JSON Schema, SQL)
• Definition et application de metriques de qualite sur des donnees generees
• Detection d'hallucinations et mise en place de filtres de validation

JOUR 4

# Securisation, industrialisation et cas d'usage avances

7 heures — 9h00-12h30 / 13h30-17h00

## 7 Securiser et industrialiser l'usage de l'IA generative

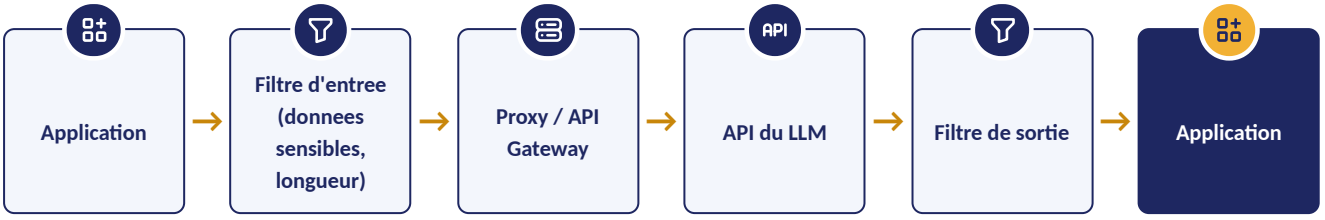
**Duree :** 3h30 | **Objectif :** Securiser une chaine d'appels IA generative et connaitre le cadre legal applicable.

### Contenu

- Aspects legaux : RGPD (minimisation, base legale, donnees personnelles dans les prompts), conditions d'utilisation des fournisseurs (OpenAI, Anthropic), reglementation europeenne (AI Act, niveaux de risque)
- Securite des API et stockage des prompts : gestion des secrets (coffre-fort/vault, variables d'environnement), chiffrement, politique de retention des logs de prompts
- Monitoring et cout des appels API : suivi de la consommation de tokens, alerting sur les depassements de budget, quotas par equipe ou projet
- Limites de responsabilite des ingenieurs : obligation de relecture humaine (human-in-the-loop) avant usage en production, tracabilite des decisions assistees par IA

SCHEMA

### Proxy de securisation d'une chaine IA




### Minutage indicatif

| Minutage | Sequence |
|---|---|
| 0-30 min | Aspects legaux : RGPD, CGU des fournisseurs, AI Act |
| 30-60 min | Securite des API et stockage des prompts |
| 60-85 min | Monitoring et cout des appels API |
| 85-105 min | Limites de responsabilite des ingenieurs |
| 105-120 min | Pause |
| 120-190 min | TP7 en autonomie |

| | |
|---|---|
| 190-210 min | Demonstration collective, bilan |

**Point de vigilance formateur**
Ce module touche directement a la politique de securite BFORBANK : rester factuel sur les principes generaux (RGPD, AI Act, bonnes pratiques) sans se substituer a la politique de securite interne de la DSI, qui prevaut toujours.

TRAVAUX PRATIQUES N°7

### Mise en place d'un proxy API avec filtrage des entrees

Duree indicative : 70 min

#### Consignes

- Concevoir (schema ou pseudo-code) un proxy applicatif s'interposant entre l'application et l'API du LLM
- Definir les regles de filtrage a appliquer sur les entrees : detection de donnees personnelles/sensibles avant envoi, longueur maximale, liste de mots-cles interdits
- Definir le niveau de logging a mettre en place : quoi logger, quoi masquer, duree de retention

### ✓ Elements de reponse — TP n°7

- Schema attendu : Application -> Filtre d'entree -> Proxy/Gateway -> API LLM -> Filtre de sortie -> Application
- Niveau de logging attendu : logger systematiquement les metadonnees et le statut de chaque appel ; masquer ou ne pas logger le contenu des prompts contenant des donnees personnelles detectees ; rétention alignee sur la politique RGPD interne (ex. 30 jours) ; alerting en cas de detection repetee de donnees sensibles

## 8 Cas d'usage avances

**Duree :** 3h30 | **Objectif :** Mettre en oeuvre un copilote IA generative sur un flux de donnees concret.

#### Contenu

- Resume automatique de logs : synthese de logs applicatifs volumineux, detection d'anomalies recurrentes, priorisation des incidents
- Documentation de code automatisee : generation de docstrings, de README, de schemas d'architecture a partir du code existant
- Generation de SQL a la volee : traduction langage naturel vers SQL (text-to-SQL), assistance a l'ecriture de requetes complexes
- IA copilote pour l'ingestion de donnees : detection automatique de schema, proposition de mapping source/cible, generation de scripts d'ingestion

SCHEMA

### 4 familles de cas d'usage avances

**Resume de logs**
Synthese, detection d'anomalies, priorisation des incidents

**Documentation de code**
Docstrings, README, schemas d'architecture generes

**Text-to-SQL**
Traduction langage naturel vers requete SQL

**Copilote d'ingestion**
Detection de schema, mapping source/cible, script genere

### Minutage indicatif

| Minutage | Sequence |
|---|---|
| 0-25 min | Resume automatique de logs |
| 25-50 min | Documentation de code automatisee |
| 50-80 min | Generation de SQL a la volee (text-to-SQL) |
| 80-105 min | IA copilote pour l'ingestion de donnees |
| 105-120 min | Pause |
| 120-190 min | TP8 en autonomie |
| 190-210 min | Demonstrations, bilan Jour 4 |

**Point de vigilance formateur**
Preparer un extrait de logs applicatifs fictifs mais realistes (formats varies : erreurs, warnings, infos) pour eviter tout usage de logs reels issus de systemes BFORBANK.

TRAVAUX PRATIQUES N°8

## Assistant generatif pour analyser des logs

Duree indicative : 70 min

### Consignes

- A partir d'un extrait de logs fourni (ou simule), rediger un prompt permettant d'obtenir un resume structure (nombre d'erreurs, types d'erreurs, recommandation)
- Tester le prompt et evaluer la pertinence du resume obtenu
- Identifier les types de logs les mieux adaptes a un traitement par IA generative, et ceux qui ne le sont pas

## ✓ Elements de reponse — TP n°8

- Prompt attendu : role 'analyste SRE' + logs en entree + consigne de sortie structuree (JSON ou tableau : nb erreurs, types, criticite, recommandation)
- Logs bien adaptes a l'IA generative : logs texte semi-structures avec messages explicites (erreurs applicatives, stack traces courtes). Logs mal adaptes : logs tres volumineux, binaires, ou purement numeriques (metriques), mieux traites par des outils de monitoring classiques et des regles deterministes

**Bilan de fin de journee — Jour 4**

• Cadre legal (RGPD, AI Act) et bonnes pratiques de securisation d'une chaine IA
• Monitoring des couts et principe du human-in-the-loop
• Cas d'usage avances : logs, documentation de code, text-to-SQL, copilote d'ingestion

JOUR 5

# Projet de fin : pipeline intelligent

7 heures — 9h00-12h30 / 13h30-17h00

## 9 Design d'un projet integrant un LLM

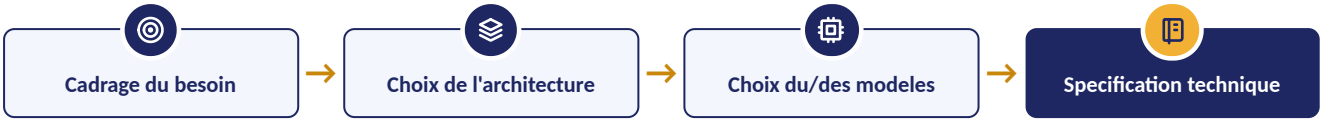
**Duree :** 3h30 | **Objectif :** Cadrer et concevoir l'architecture du pipeline intelligent du projet fil rouge.

### Contenu

- Cadrage du besoin : definir un cas d'usage data engineering concret a resoudre avec un LLM (donnees de test, documentation, requetage, resume de logs...)
- Choix de l'architecture : appel API direct vs orchestration LangChain, modele unique vs routing multi-modeles, synchrone vs asynchrone
- Choix du ou des modeles : criteres de decision (cout, latence, qualite, confidentialite), modele cloud vs local
- Specification technique : schema d'entree/sortie, contraintes de validation, strategie de gestion des erreurs

SCHEMA

### De l'idee a la specification technique




*Chaque etape est validee par le formateur avant de passer a la suivante, pour eviter un cadrage trop ambitieux*

### Minutage indicatif

| Minutage | Sequence |
|---|---|
| 0-20 min | Lancement du projet fil rouge, presentation des consignes (voir Projet pedagogique) |
| 20-50 min | Cadrage du besoin, choix du cas d'usage par groupe |
| 50-90 min | Choix de l'architecture et des modeles |
| 90-120 min | Redaction de la specification technique |
| 120-135 min | Pause |
| 135-210 min | Travail en autonomie sur le projet (conception + debut d'implementation) |

**Point de vigilance formateur**
Constituer les groupes projet en debut de matinee (3-4 personnes). Faire valider par le formateur le cas d'usage et l'architecture de chaque groupe avant la pause, pour eviter un cadrage trop ambitieux impossible a tenir en une journee.

## 10 Tests, evaluation, monitoring et presentation des projets

**Duree :** 3h30 | **Objectif :** Finaliser, tester et presenter le pipeline intelligent concu le matin.

### Contenu

- Strategie de test : jeux de test representatifs, cas limites, prompts adverses
- Evaluation : application des metriques vues en Jour 3 (conformite, plausibilite, hallucinations), controle humain
- Monitoring : logging et gestion des couts, vus en Jour 4, appliques au pipeline du projet
- Presentation des projets a la classe : format de restitution, grille d'evaluation, retours d'experience

SCHEMA

### De la validation a la restitution




*Un pipeline n'est termine que lorsqu'il a ete teste sur des cas limites et que son cout/latence a ete mesure*

### Minutage indicatif

| Minutage | Sequence |
|---|---|
| 0-90 min | Finalisation de l'implementation en autonomie (par groupe) |
| 90-120 min | Tests et evaluation du pipeline realise |
| 120-135 min | Pause |
| 135-180 min | Presentation des projets a la classe (10 min par groupe) |
| 180-200 min | Debriefing collectif, quiz de revision |
| 200-210 min | Bilan de la formation, evaluation a chaud |

**Point de vigilance formateur**
Cadrer strictement le temps de presentation (10 minutes par groupe, questions comprises) pour que tous les groupes passent. Utiliser la grille d'evaluation du Projet pedagogique pour cadrer le retour donne a chaque groupe.

## 9-10 Projet fil rouge : Conception d'un pipeline intelligent

Le dernier jour de la formation est consacre a un projet de synthese realise en petits groupes (3 a 4 personnes). Chaque groupe concoit, implemente et presente un pipeline de donnees integrant un ou plusieurs appels a un LLM, en appliquant l'ensemble des notions vues durant la semaine : manipulation de l'API, orchestration, generation et validation de donnees, securisation, monitoring.

### Cas d'usage suggeres

- Generateur de jeux de donnees de test synthetiques et valides pour un environnement de recette
- Assistant de documentation automatique d'un schema de donnees ou d'un pipeline existant
- Copilote de generation de requetes SQL a partir d'une demande en langage naturel
- Assistant de resume et de priorisation de logs applicatifs
- Pipeline d'anonymisation assistee par IA d'un jeu de donnees fictif

### Livrables attendus

- Une specification courte (1 page) : cas d'usage, schema d'entree/sortie, contraintes de validation
- Un pipeline fonctionnel (script ou notebook Python) integrant au moins un appel LLM et une etape de validation de la sortie
- Un mecanisme de logging minimal (prompt, reponse, duree, statut) sur chaque appel
- Un jeu de test (au moins 3 cas, dont 1 cas limite ou adverse) et les resultats obtenus
- Une mesure indicative du cout et de la latence du pipeline sur le jeu de test
- Un support de presentation de 10 minutes (slides ou demonstration live)

### Contraintes

- Aucune donnee reelle ou de production BFORBANK ne doit etre utilisee : uniquement des donnees fictives
- Toute cle d'API doit etre geree via une variable d'environnement, jamais en dur dans le code
- Le pipeline doit inclure une etape de validation de la sortie du LLM (schema, regle metier ou controle humain)
- Le code doit rester dans le perimetre du depot Git de la formation (pas de diffusion externe)

### Planning du Jour 5

| Horaire | Sequence |
|---|---|
| 9h00 - 9h20 | Lancement, presentation des consignes et des cas d'usage suggeres |
| 9h20 - 11h15 | Cadrage (module 9) : choix du cas d'usage, architecture, specification technique |
| 11h15 - 12h30 | Debut d'implementation en autonomie (sur la base de la specification validee) |
| 12h30 - 13h30 | Pause dejeuner |
| 13h30 - 15h00 | Implementation du pipeline en autonomie |
| 15h00 - 15h30 | Tests, evaluation, mesure du cout et de la latence |
| 15h30 - 15h45 | Pause |
| 15h45 - 16h30 | Presentations des projets (10 min par groupe) |
| 16h30 - 17h00 | Debriefing collectif, quiz de revision, bilan de formation |

### Grille d'evaluation (retour formatif)

| Critere | Ce qui est observe |
|---|---|
| **Pertinence du cas d'usage** | Le cas d'usage choisi apporte une valeur claire pour un Data Engineer et le risque identifie est maitrise |
| **Qualite de l'architecture** | Les choix d'architecture (modele, orchestration, synchrone/asynchrone) sont justifies et adaptes au besoin |
| **Robustesse du pipeline** | La sortie du LLM est validee ; le pipeline gere au moins un cas limite sans echec silencieux |
| **Securite et conformite** | Aucune donnee reelle utilisee, cles API gerees correctement, logging en place |
| **Qualite de la presentation** | La demonstration est claire, tient dans le temps imparti et explicite les retours d'experience |

*Cette grille est utilisee pour un retour formatif oral a chaque groupe en fin de journee ; elle ne donne pas lieu a une notation individuelle.*

**Point de vigilance formateur**
Detail complet des consignes et de la grille : voir le document distinct « Projet pedagogique », remis en complement de ce guide.

**Bilan de la formation**
• Conception, implementation et presentation d'un pipeline intelligent integrant un LLM
• Mise en pratique de l'ensemble des notions de la semaine : appels API, orchestration, generation et validation de donnees, securisation, monitoring
• Formation terminee : penser a distribuer et collecter le questionnaire de satisfaction a chaud

# Annexe A — Quiz de revision (corrige)

**1. Quelle est la difference fondamentale entre IA classique et IA generative ?**

L'IA classique produit une sortie bornee (une classe, un score) a partir de regles ou d'un apprentissage supervise ; l'IA generative produit un contenu nouveau (texte, code, donnees) a partir de modeles pre-entraines sur de grands volumes de donnees.

**2. Qu'est-ce qu'un token et pourquoi son nombre influence-t-il le cout d'un appel API a un LLM ?**

Un token est une unite de decoupage du texte (mot, sous-mot ou caractere) manipulee par le modele. Le nombre total de tokens en entree et en sortie determine directement le cout facture et la latence de la reponse.

**3. A quoi sert le parametre 'temperature' lors d'un appel a un LLM ?**

Il controle le caractere aleatoire/creatif de la generation : une temperature basse donne des reponses plus deterministes et reproductibles, une temperature elevee donne des reponses plus diverses mais moins previsibles.

**4. Pourquoi ne faut-il jamais ecrire une cle d'API directement dans le code ?**

Risque de fuite (depot de code, historique Git), de facturation frauduleuse et de compromission du compte. Il faut utiliser une variable d'environnement ou un gestionnaire de secrets, jamais une valeur en dur.

**5. Citez deux mecanismes permettant d'orchestrer plusieurs appels LLM au sein d'un meme traitement (LangChain).**

Les prompts chaines (chains, plusieurs appels successifs decomposant une tache complexe) et le couplage de modeles hybrides (routing entre un LLM puissant et un LLM leger selon l'etape, pour optimiser cout et latence).

**6. Quelles sont les grandes etapes d'un pipeline de generation de donnees synthetiques ?**

Definition du schema cible (JSON Schema ou DDL), redaction du prompt de generation, appel au LLM, validation de la sortie (conformite au schema et aux contraintes metier), puis obtention du jeu de donnees valide.

**7. Citez deux metriques permettant d'evaluer la qualite d'un jeu de donnees genere par IA.**

Le taux de conformite au schema attendu, la plausibilite statistique des valeurs, l'absence de doublons/la diversite, et la coherence referentielle (cles etrangeres) sont des metriques attendues (2 suffisent).

**8. Qu'est-ce qu'une hallucination et comment peut-on la limiter ?**

Une hallucination est une information inventee par le LLM mais presentee comme factuelle. On la limite par la validation systematique de la sortie, le recoupement avec une source de verite et le controle humain (human-in-the-loop).

**9. Quelles sont les principales obligations a respecter lors de l'usage d'un LLM sur des donnees d'entreprise (RGPD) ?**

Minimiser les donnees personnelles envoyees dans les prompts, disposer d'une base legale, connaitre la politique de sous-traitance et de transfert du fournisseur, tracer les traitements et respecter une politique de retention des logs.

**10. Pourquoi le principe de 'human-in-the-loop' est-il essentiel avant tout usage en production d'une sortie generee par IA ?**

Parce qu'un LLM peut halluciner ou produire un resultat biaise ; une relecture humaine avant usage en production limite le risque d'erreur et permet d'engager la responsabilite de facon maitrisee.

# Annexe B — Modalites pedagogiques et evaluation

## Pedagogie

- Alternance apports theoriques courts, demonstrations en direct avec des LLM et travaux pratiques
- 1 travail pratique par module, en lien direct avec la theorie qui precede
- Projet fil rouge le dernier jour : conception d'un pipeline intelligent integrant un LLM
- Debriefing ou correction collective apres chaque TP
- Utilisation exclusive de donnees fictives : aucune donnee reelle ou de production BFORBANK n'est manipulee

## Evaluation

- Evaluation formative continue (observation pendant les travaux pratiques)
- Quiz de revision en fin de parcours (10 questions couvrant les 5 jours)
- Qualite et conformite des donnees synthetiques produites (TP5, TP6)
- Soutenance du projet fil rouge devant le groupe (Jour 5)
- Questionnaire de satisfaction a chaud en fin de formation