LIVRET APPRENANT

L'IA generative pour les Data Engineers

Cours, exemples, travaux pratiques et espace de prise de notes

Client : BFORBANK

Lieu : Presentiel a Paris La Defense

Du 19 au 23 octobre 2026 — 5 jours / 35 heures

Ce livret est le votre : gardez-le, annotez-le, il vous servira de reference apres la formation.

Sommaire

Fiche formation 3

Jour 1 — Fondamentaux de l'IA generative 5

Jour 2 — Manipulation de LLM avec Python et LangChain 8

Jour 3 — Generation et evaluation de donnees synthetiques 11

Jour 4 — Securisation, industrialisation et cas d'usage avances 14

Jour 5 — Projet de fin : pipeline intelligent 17

Quiz de revision 20

Pour aller plus loin 21

Mes notes 22

Fiche formation

Intitule : L'IA generative pour les Data Engineers

Duree : 5 jours / 35 heures

Client : BFORBANK | **Lieu :** Presentiel a Paris La Defense

Dates : Du 19 au 23 octobre 2026

Horaires : Jour 1 : 9h15 (installation formateur) - 9h30-13h00 / 14h00-17h30 | Jours 2 a 5 : 9h00-12h30 / 13h30-17h00

Prerequis apprenants

- Bonne maitrise de Python (fonctions, structures de donnees, environnements virtuels)
- Connaissance des architectures de donnees (pipelines ETL/ELT, bases relationnelles, formats semi-structures)
- Connaissance des API REST (methodes HTTP, authentification, format JSON)
- A l'aise avec au moins un outil cloud (stockage, calcul ou orchestration)

Public cible

- Data Engineers
- Data Architects
- Developpeurs backend en charge de flux de donnees
- Ingenieurs data en charge des pipelines de traitement de donnees

Objectifs pedagogiques

- Comprendre les concepts fondamentaux de l'IA generative
- Identifier les cas d'usage pertinents pour les Data Engineers
- Manipuler des modeles de langage comme GPT dans des flux de traitement
- Generer et valider des donnees synthetiques pour enrichir les jeux de donnees
- Automatiser certaines taches grace a des API d'IA generative
- Evaluer les risques ethiques et de securite lies a ces usages

Materiel et prerequis techniques

- Un ordinateur par participant avec un IDE Python (VS Code recommande) et Python 3.10 ou superieur
- Acces internet stable autorisant les appels vers les API OpenAI / Anthropic (a valider en amont avec la DSI BFORBANK)
- Cle(s) API OpenAI et/ou Anthropic fournies par le formateur ou l'organisme, selon la politique de securite BFORBANK
- Environnement Python avec les bibliotheques openai, langchain, pydantic, jsonschema, faker (requirements.txt fourni en amont)

- Acces a un depot Git pour recuperer les squelettes de TP et deposer le projet fil rouge du Jour 5
- Aucune donnee reelle ou de production BFORBANK n'est utilisee : tous les TP s'appuient sur des jeux de donnees fictifs

JOUR 1

Fondamentaux de l'IA generative

7 heures — 9h15 (installation formateur) - 9h30-13h00 / 14h00-17h30

1 Fondamentaux de l'IA generative

Diapositives 7-11

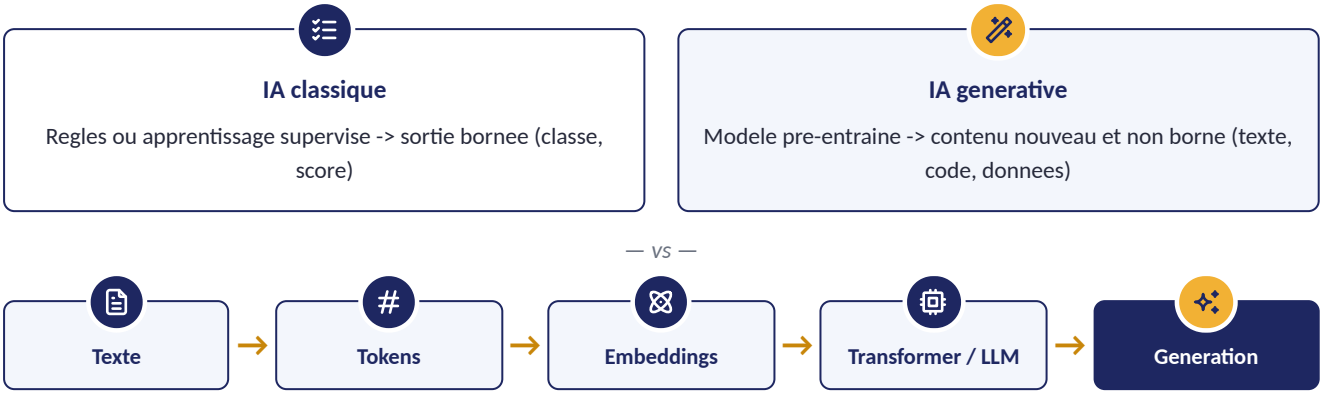
Duree : 3h30 | **Objectif :** Comprendre les concepts fondamentaux de l'IA generative et le principe de fonctionnement des LLM.

Ce qu'il faut savoir

- Definition de l'IA generative : des modeles capables de produire du contenu inedit (texte, code, image, donnees) plutot que de seulement classer ou predire
- Historique resume : des reseaux de neurones classiques aux Transformers (2017), puis aux LLM grand public (GPT-3, ChatGPT en 2022)
- IA classique (regles, scoring, classification supervisee) versus IA generative (production de contenu nouveau par des modeles pre-entraines)
- Panorama des modeles existants : LLM texte (GPT, Claude, Llama, Mistral), generation d'image (DALL-E, Stable Diffusion), modeles multimodaux
- Principes de fonctionnement d'un LLM : tokenisation, embeddings, mecanisme d'attention, generation autoregressive token par token
- Notion de parametres, de fenetre de contexte (context window), et distinction fine-tuning versus prompt engineering
- Panorama des plateformes : Hugging Face (hub de modeles), OpenAI, Anthropic, Mistral AI, Google

SCHEMA

IA classique vs IA generative, et pipeline d'un LLM



A retenir
Retenez la chaine Texte -> Tokens -> Embeddings -> Transformer -> Generation : c'est le socle commun a tous les LLM que vous manipulerez cette semaine.

TRAVAUX PRATIQUES N°1

Exploration interactive de modeles sur Hugging Face

Duree indicative : 55 min

Consignes

- Se rendre sur huggingface.co et explorer le Hub de modeles en filtrant par tache (text-generation, text-classification)
- Comparer un modele de classification (ex. BERT fine-tune pour l'analyse de sentiment) et un LLM generatif (ex. Mistral-7B-Instruct, GPT-2) : nombre de parametres, carte modele (model card), tache visee
- Tester le widget d'inference en ligne sur 2 a 3 modeles et noter les differences de sortie obtenues
- Lister 3 criteres permettant de distinguer un LLM d'un modele classique de machine learning

Mon code / mes notes

2 Usages et enjeux pour les Data Engineers

Diapositives 12–15

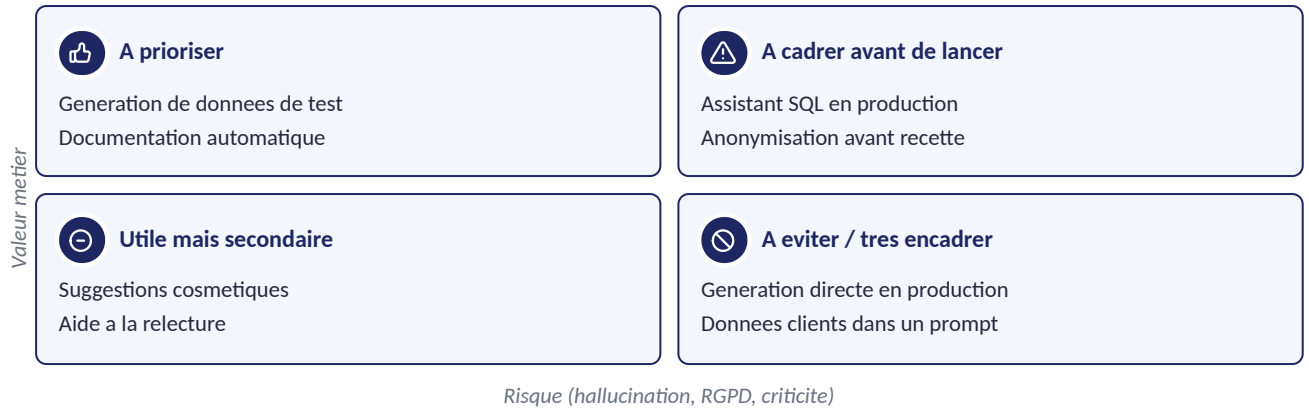
Duree : 3h30 | **Objectif :** Identifier les cas d'usage de l'IA generative pertinents pour un Data Engineer et les risques associes.

Ce qu'il faut savoir

- Generation de donnees synthetiques : pourquoi (jeux de test, environnements de recette, equilibrage de classes rares) et comment (prompt structure, bibliotheques dediees)
- Anonymisation de donnees via IA : pseudonymisation assistee, generation de substituts realistes preservant la structure statistique des donnees d'origine
- Assistants intelligents pour les pipelines de donnees : generation de requetes SQL, documentation automatique de schemas, aide au debug de jobs ETL/ELT
- Risques : hallucinations (invention de faits ou de valeurs), biais herites des donnees d'entrainement, non-conformite RGPD (donnees personnelles dans les prompts, transfert hors UE)
- Panorama des cas d'usage prioritaires pour un Data Engineer : qualite de donnees, documentation, generation de tests, acceleration du developpement de pipelines

SCHEMA

Prioriser un cas d'usage : valeur vs risque



A retenir
Face a un cas d'usage IA generative, posez-vous toujours 2 questions : quelle valeur metier, et quel risque (hallucination, RGPD, criticite) ?

TRAVAUX PRATIQUES N°2

Etude de cas en binomes : quel cas d'usage prioriser ?

Duree indicative : 65 min

Consignes

- En binome, choisir un pipeline ou un jeu de donnees representatif de votre contexte (ou un cas bancaire fictif propose par le formateur)
- Lister 3 cas d'usage possibles de l'IA generative sur ce pipeline (generation de donnees de test, documentation, detection d'anomalies...)
- Prioriser ces cas d'usage selon 2 criteres : valeur metier et risque (RGPD, hallucination, criticite du systeme)
- Restituer en 5 minutes maximum a l'ensemble du groupe

Mon code / mes notes

Ce qu'il faut retenir — Jour 1
- Panorama de l'IA generative, de son historique et des grandes familles de modeles
- Cas d'usage et risques (hallucinations, biais, RGPD) pour un Data Engineer
- Premiere manipulation exploratoire de modeles sur Hugging Face

JOUR 2

Manipulation de LLM avec Python et LangChain

7 heures — 9h00-12h30 / 13h30-17h00

3 Manipulation de LLM avec Python

Diapositives 18–22

Duree : 3h30 | **Objectif :** Maitriser les appels a une API d'IA generative depuis Python et la validation des reponses obtenues.

Ce qu'il faut savoir

- Introduction a l'API OpenAI (ChatGPT) : modeles disponibles, endpoint de chat completions
- Authentification et gestion des cles API : variable d'environnement, jamais de cle en dur dans le code
- Parametres d'appel : messages system/user/assistant, temperature (creativite), max_tokens, top_p
- Notion de token : unite de decoupage du texte, impact direct sur le cout et la latence d'un appel
- Traitement des retours : structuration de la reponse, parsing JSON, validation du format attendu (pydantic, jsonschema)
- Integration dans un pipeline de donnees : appel LLM comme etape d'un pipeline Python, gestion des erreurs et des retries

SCHEMA

Anatomie d'un appel API LLM dans un pipeline



A retenir

Ne jamais faire confiance aveuglement a une sortie de LLM : un prompt mal formule produit une reponse plausible mais non fiable. Validez systematiquement le format et le contenu.

TRAVAUX PRATIQUES N°3

Script Python pour interroger un LLM

Duree indicative : 60 min

Consignes

- Ecrire un script Python qui envoie un prompt a l'API OpenAI (ou Anthropic) et affiche la reponse
- Parametrer la temperature et observer l'effet sur des appels repetes avec le meme prompt
- Demander une sortie structuree en JSON (ex. extraction d'entites d'un texte) et la parser avec le module json

- Tester volontairement un prompt ambigu ou incomplet et observer le comportement du modele

Mon code / mes notes

4 LangChain pour orchestrer les LLM

Diapositives 23-26

Duree : 3h30 | **Objectif :** Orchestrer plusieurs appels a des LLM au sein d'un meme traitement, avec logging et observabilite.

Ce qu'il faut savoir

- Introduction a LangChain : chaines (chains), composants (prompts, modeles, parsers), notion d'agent intelligent
- Prompts chaines : decomposer une tache complexe en plusieurs appels successifs
- Modeles hybrides : combiner un LLM puissant et un modele plus leger selon l'etape (routing, cout, latence)
- Memorisation et gestion de l'etat : conserver le contexte d'une conversation ou d'un pipeline multi-etapes
- Logging, monitoring et observabilite : tracer les appels, les prompts, les couts et les temps de reponse

SCHEMA

Chaine LangChain simulant un ETL



Logging a chaque etape : prompt envoye, reponse recue, duree, statut

A retenir
Une chaine de prompts n'est robuste que si chaque etape est loguee et validee independamment : ne jamais enchainer des appels IA sans point de controle intermediaire.

TRAVAUX PRATIQUES N°4

Conception d'un assistant generatif simulant un ETL

Duree indicative : 75 min

Consignes

- Concevoir avec LangChain (ou une chaine de prompts manuelle) un mini pipeline en 3 etapes : extraction d'un texte source, transformation/nettoyage assiste par LLM, generation d'un resume structure
- Ajouter un mecanisme de logging a chaque etape (prompt envoye, reponse recue, duree)

- Documenter les mecanismes de logging necessaires dans un contexte de production bancaire (tracabilite, audit)

Mon code / mes notes

Ce qu'il faut retenir — Jour 2

• Maitrise des appels a l'API d'un LLM depuis Python (parametres, parsing, validation)
• Orchestration de plusieurs appels avec LangChain : chaines, memoire, logging
• Bonne pratique : ne jamais exposer une cle d'API dans le code

JOUR 3

Generation et evaluation de donnees synthetiques

7 heures — 9h00-12h30 / 13h30-17h00

5 Generation de donnees synthetiques

Diapositives 29–32

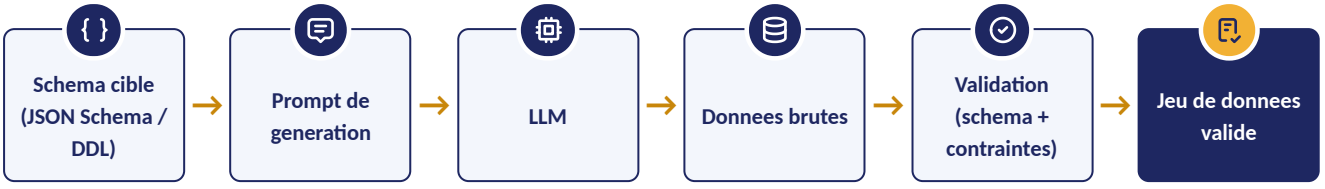
Duree : 3h30 | **Objectif :** Generer des donnees synthetiques conformes a un schema cible, dans le respect du RGPD.

Ce qu'il faut savoir

- Cas d'usage de la generation : jeux de test, environnements de recette, anonymisation par substitution, equilibrage de classes rares en ML
- Methodes d'augmentation de donnees : generation par prompt structure, bibliotheques specialisees (Faker couple a un LLM, Synthetic Data Vault), generation conditionnelle
- Generation de schemas conformes : JSON Schema pour structurer la sortie, generation de DDL SQL conforme a un schema de donnees existant
- Validation des jeux synthetiques : coherence referentielle (cles etrangeres), respect des contraintes metier, absence de fuite de donnees reelles

SCHEMA

Pipeline de generation de donnees synthetiques



A retenir
Un jeu de donnees synthetique n'est utilisable que s'il est a la fois plausible ET verifiable : toujours valider automatiquement le schema et les contraintes avant de le considerer exploitable.

TRAVAUX PRATIQUES N°5

Generation d'un dataset RH conforme RGPD

Duree indicative : 70 min

Consignes

- Definir un schema de donnees RH (matricule, nom, prenom, date de naissance, poste, departement, date d'entree)
- Rediger un prompt de generation produisant N enregistrements respectant ce schema, avec des valeurs realistes mais entierement fictives

- Verifier la coherence des donnees generees (types, plages de valeurs, unicite du matricule)
- Documenter comment garantir qu'aucune donnee reelle ne s'est glissee dans le jeu genere

Mon code / mes notes

6 Evaluation de la qualite de sortie

Diapositives 33–36

Duree : 3h30 | **Objectif :** Evaluer et fiabiliser la qualite d'une sortie generee par un LLM.

Ce qu'il faut savoir

- Metriques qualite sur donnees generees : taux de conformite au schema, diversite (absence de duplication excessive), plausibilite statistique
- Outils de validation semantique : comparaison par embeddings, LLM-as-a-judge (faire evaluer une sortie par un second appel LLM)
- Detection d'hallucinations et filtres : recoupement avec une source de verite, filtrage par regles metier, score de confiance
- Post-traitement et enrichissement : nettoyage, normalisation, complement d'information par appel API ou jointure avec un referentiel

SCHEMA

Chaine d'evaluation d'une sortie LLM



Un enregistrement qui echoue le filtre est rejete ou regenere, jamais integre tel quel au jeu final

A retenir
La qualite d'une sortie generative ne se juge jamais au feeling : definissez vos metriques (conformite, plausibilite, diversite) avant de generer, pas apres.

TRAVAUX PRATIQUES N°6

Evaluation qualite d'un output genere par GPT

Duree indicative : 70 min

Consignes

- Reprendre le jeu de donnees RH genere au TP5 (ou un jeu fourni par le formateur)
- Definir 3 metriques de qualite : conformite de schema, plausibilite des valeurs, absence de doublons
- Identifier les enregistrements suspects (noms incoherents, valeurs hors plage, doublons)
- Proposer une action corrective pour chaque anomalie detectee

Mon code / mes notes

Ce qu'il faut retenir — Jour 3

• Generation de donnees synthetiques conformes a un schema cible (JSON Schema, SQL)
• Definition et application de metriques de qualite sur des donnees generees
• Detection d'hallucinations et mise en place de filtres de validation

JOUR 4

Securisation, industrialisation et cas d'usage avances

7 heures — 9h00-12h30 / 13h30-17h00

7 Securiser et industrialiser l'usage de l'IA generative

Diapositives 39–42

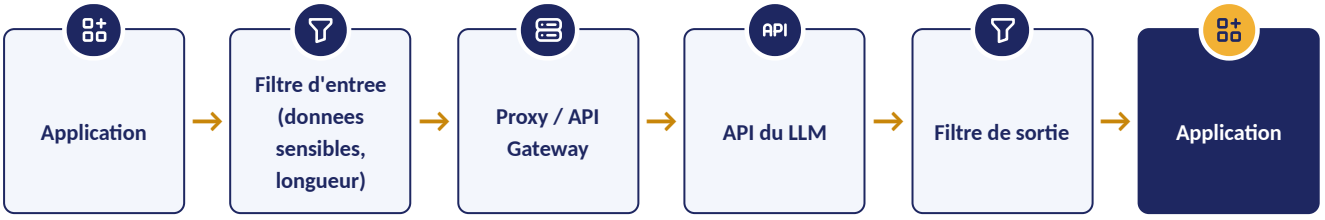
Duree : 3h30 | **Objectif :** Securiser une chaine d'appels IA generative et connaitre le cadre legal applicable.

Ce qu'il faut savoir

- Aspects legaux : RGPD (minimisation, base legale, donnees personnelles dans les prompts), conditions d'utilisation des fournisseurs (OpenAI, Anthropic), reglementation europeenne (AI Act, niveaux de risque)
- Securite des API et stockage des prompts : gestion des secrets (coffre-fort/vault, variables d'environnement), chiffrement, politique de retention des logs de prompts
- Monitoring et cout des appels API : suivi de la consommation de tokens, alerting sur les depassements de budget, quotas par equipe ou projet
- Limites de responsabilite des ingenieurs : obligation de relecture humaine (human-in-the-loop) avant usage en production, tracabilite des decisions assistees par IA

SCHEMA

Proxy de securisation d'une chaine IA



A retenir

Une chaine IA n'est consideree securisee que si elle filtre les entrees ET les sorties, et que chaque appel reste tracable et attribuable a un usage precis.

TRAVAUX PRATIQUES N°7

Mise en place d'un proxy API avec filtrage des entrees

Duree indicative : 70 min

Consignes

- Concevoir (schema ou pseudo-code) un proxy applicatif s'interposant entre l'application et l'API du LLM
- Definir les regles de filtrage a appliquer sur les entrees : detection de donnees personnelles/sensibles avant envoi, longueur maximale, liste de mots-cles interdits

- Definir le niveau de logging a mettre en place : quoi logger, quoi masquer, duree de retention

Mon code / mes notes

8 Cas d'usage avances

Diapositives 43–46

Duree : 3h30 | **Objectif :** Mettre en oeuvre un copilote IA generative sur un flux de donnees concret.

Ce qu'il faut savoir

- Resume automatique de logs : synthese de logs applicatifs volumineux, detection d'anomalies recurrentes, priorisation des incidents
- Documentation de code automatisee : generation de docstrings, de README, de schemas d'architecture a partir du code existant
- Generation de SQL a la volee : traduction langage naturel vers SQL (text-to-SQL), assistance a l'ecriture de requetes complexes
- IA copilote pour l'ingestion de donnees : detection automatique de schema, proposition de mapping source/cible, generation de scripts d'ingestion

SCHEMA

4 familles de cas d'usage avances

Resume de logs
Synthese, detection d'anomalies, priorisation des incidents

Documentation de code
Docstrings, README, schemas d'architecture generes

Text-to-SQL
Traduction langage naturel vers requete SQL

Copilote d'ingestion
Detection de schema, mapping source/cible, script genere

A retenir
L'IA generative excelle sur les logs texte semi-structures et explicites ; elle n'est pas le bon outil pour du monitoring de metriques strictement numeriques, mieux traite par des regles deterministes.

TRAVAUX PRATIQUES N°8

Assistant generatif pour analyser des logs

Duree indicative : 70 min

Consignes

- A partir d'un extrait de logs fourni (ou simule), rediger un prompt permettant d'obtenir un resume structure (nombre d'erreurs, types d'erreurs, recommandation)
- Tester le prompt et evaluer la pertinence du resume obtenu
- Identifier les types de logs les mieux adaptes a un traitement par IA generative, et ceux qui ne le sont pas

Mon code / mes notes

Ce qu'il faut retenir — Jour 4

• Cadre legal (RGPD, AI Act) et bonnes pratiques de securisation d'une chaine IA
• Monitoring des couts et principe du human-in-the-loop
• Cas d'usage avances : logs, documentation de code, text-to-SQL, copilote d'ingestion

JOUR 5

Projet de fin : pipeline intelligent

7 heures — 9h00-12h30 / 13h30-17h00

9 Design d'un projet integrant un LLM

Diapositives 49–50

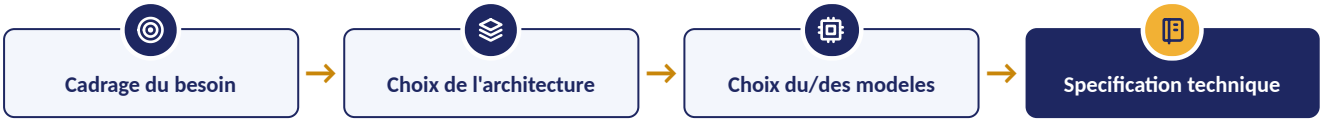
Duree : 3h30 | **Objectif :** Cadrer et concevoir l'architecture du pipeline intelligent du projet fil rouge.

Ce qu'il faut savoir

- Cadrage du besoin : definir un cas d'usage data engineering concret a resoudre avec un LLM (donnees de test, documentation, requetage, resume de logs...)
- Choix de l'architecture : appel API direct vs orchestration LangChain, modele unique vs routing multi-modeles, synchrone vs asynchrone
- Choix du ou des modeles : criteres de decision (cout, latence, qualite, confidentialite), modele cloud vs local
- Specification technique : schema d'entree/sortie, contraintes de validation, strategie de gestion des erreurs

SCHEMA

De l'idee a la specification technique



Chaque etape est validee par le formateur avant de passer a la suivante, pour eviter un cadrage trop ambitieux

A retenir
Un bon cadrage de projet IA generative tient sur une page : cas d'usage, entree/sortie, contraintes, criteres de succes. Si ce n'est pas le cas, le perimetre est trop large.

10 Tests, evaluation, monitoring et presentation des projets

Diapositives 51–54

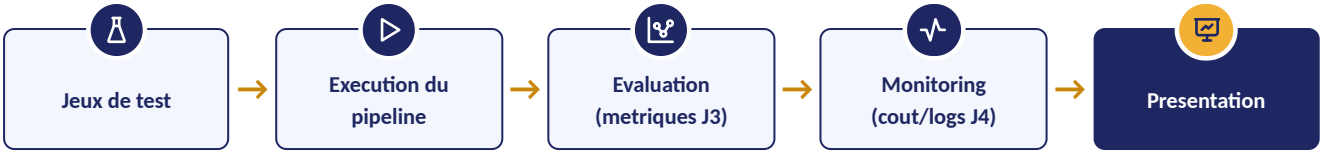
Duree : 3h30 | **Objectif :** Finaliser, tester et presenter le pipeline intelligent concu le matin.

Ce qu'il faut savoir

- Strategie de test : jeux de test representatifs, cas limites, prompts adverses
- Evaluation : application des metriques vues en Jour 3 (conformite, plausibilite, hallucinations), controle humain
- Monitoring : logging et gestion des couts, vus en Jour 4, appliques au pipeline du projet
- Presentation des projets a la classe : format de restitution, grille d'evaluation, retours d'experience

SCHEMA

De la validation a la restitution



Un pipeline n'est termine que lorsqu'il a ete teste sur des cas limites et que son cout/latence a ete mesure

A retenir
Un pipeline intelligent n'est termine que lorsqu'il a ete teste sur des cas limites et que son cout/latence a ete mesure, pas seulement lorsqu'il fonctionne sur le cas nominal.

9-10 Projet fil rouge : Conception d'un pipeline intelligent

Le dernier jour de la formation est consacre a un projet de synthese realise en petits groupes (3 a 4 personnes). Chaque groupe concoit, implemente et presente un pipeline de donnees integrant un ou plusieurs appels a un LLM, en appliquant l'ensemble des notions vues durant la semaine : manipulation de l'API, orchestration, generation et validation de donnees, securisation, monitoring.

Cas d'usage suggeres

- Generateur de jeux de donnees de test synthetiques et valides pour un environnement de recette
- Assistant de documentation automatique d'un schema de donnees ou d'un pipeline existant
- Copilote de generation de requetes SQL a partir d'une demande en langage naturel
- Assistant de resume et de priorisation de logs applicatifs
- Pipeline d'anonymisation assistee par IA d'un jeu de donnees fictif

Livrables attendus

- Une specification courte (1 page) : cas d'usage, schema d'entree/sortie, contraintes de validation
- Un pipeline fonctionnel (script ou notebook Python) integrant au moins un appel LLM et une etape de validation de la sortie
- Un mecanisme de logging minimal (prompt, reponse, duree, statut) sur chaque appel
- Un jeu de test (au moins 3 cas, dont 1 cas limite ou adverse) et les resultats obtenus
- Une mesure indicative du cout et de la latence du pipeline sur le jeu de test
- Un support de presentation de 10 minutes (slides ou demonstration live)

Contraintes

- Aucune donnee reelle ou de production BFORBANK ne doit etre utilisee : uniquement des donnees fictives
- Toute cle d'API doit etre geree via une variable d'environnement, jamais en dur dans le code
- Le pipeline doit inclure une etape de validation de la sortie du LLM (schema, regle metier ou controle humain)
- Le code doit rester dans le perimetre du depot Git de la formation (pas de diffusion externe)

Planning du Jour 5

Horaire	Sequence
9h00 - 9h20	Lancement, presentation des consignes et des cas d'usage suggeres
9h20 - 11h15	Cadrage (module 9) : choix du cas d'usage, architecture, specification technique
11h15 - 12h30	Debut d'implementation en autonomie (sur la base de la specification validee)
12h30 - 13h30	Pause dejeuner
13h30 - 15h00	Implementation du pipeline en autonomie
15h00 - 15h30	Tests, evaluation, mesure du cout et de la latence
15h30 - 15h45	Pause
15h45 - 16h30	Presentations des projets (10 min par groupe)
16h30 - 17h00	Debriefing collectif, quiz de revision, bilan de formation

Le detail complet du projet (contexte, livrables, planning, grille d'evaluation) figure dans le document « Projet pedagogique » remis separement.

Notes de projet

Quiz de revision

A vous de jouer ! Repondez aux questions ci-dessous avant la correction collective avec votre formateur.

1. Quelle est la difference fondamentale entre IA classique et IA generative ?

2. Qu'est-ce qu'un token et pourquoi son nombre influence-t-il le cout d'un appel API a un LLM ?

3. A quoi sert le parametre 'temperature' lors d'un appel a un LLM ?

4. Pourquoi ne faut-il jamais ecrire une cle d'API directement dans le code ?

5. Citez deux mecanismes permettant d'orchestrer plusieurs appels LLM au sein d'un meme traitement (LangChain).

6. Quelles sont les grandes etapes d'un pipeline de generation de donnees synthetiques ?

7. Citez deux metriques permettant d'evaluer la qualite d'un jeu de donnees genere par IA.

8. Qu'est-ce qu'une hallucination et comment peut-on la limiter ?

9. Quelles sont les principales obligations a respecter lors de l'usage d'un LLM sur des donnees d'entreprise (RGPD) ?

10. Pourquoi le principe de 'human-in-the-loop' est-il essentiel avant tout usage en production d'une sortie generee par IA ?

Pour aller plus loin

La formation touche a sa fin, mais l'ecosysteme de l'IA generative pour les Data Engineers evolue tres vite. Voici quelques pistes pour continuer a progresser :

- Agents IA multi-etapes : automatiser des taches complexes en enchainant plusieurs appels a un LLM
- Fine-tuning : specialiser un modele sur des donnees propres a l'entreprise
- Model Context Protocol (MCP) : standard emergent pour connecter des LLM a des outils et donnees externes
- Retrieval-Augmented Generation (RAG) : enrichir un LLM avec une base documentaire pour aller au-dela du contexte vu cette semaine
- Observabilite des applications IA : suivre couts, latence et qualite des reponses en production
- Veille reglementaire : suivre l'entree en application progressive de l'AI Act europeen

Merci et bonne continuation !

Formation L'IA generative pour les Data Engineers — BFORBANK.

Mes notes

Mes notes