PROJET PEDAGOGIQUE — JOUR 5

L'IA generative pour les Data Engineers

Cahier des charges du projet fil rouge : pipeline intelligent integrant un LLM

Client : BFORBANK

Lieu : Presentiel a Paris La Defense

Du 19 au 23 octobre 2026 — 5 jours / 35 heures

Document remis a chaque groupe en debut de Jour 5 — a conserver pendant toute la journee de projet.

Projet fil rouge — Jour 5

Conception d'un pipeline intelligent

Le dernier jour de la formation est consacre a un projet de synthese realise en petits groupes (3 a 4 personnes). Chaque groupe concoit, implemente et presente un pipeline de donnees integrant un ou plusieurs appels a un LLM, en appliquant l'ensemble des notions vues durant la semaine : manipulation de l'API, orchestration, generation et validation de donnees, securisation, monitoring.

A retenir avant de commencer
Ce projet mobilise l'ensemble des notions vues du Jour 1 au Jour 4 : manipulation d'un LLM (Jour 2), generation et validation de donnees (Jour 3), securisation et monitoring (Jour 4). Prenez le temps de bien cadrer votre cas d'usage avant de coder : un perimetre clair vaut mieux qu'un pipeline ambitieux mais inacheve.

Organisation

Groupes : 3 a 4 personnes, constitues en debut de matinee du Jour 5

Duree : une journee complete (7 heures, cf. planning ci-dessous)

Restitution : presentation de 10 minutes par groupe en fin de journee

Cas d'usage suggeres

Ces pistes sont des suggestions : un groupe peut proposer un autre cas d'usage, sous reserve de validation par le formateur avant la pause du matin.

- Generateur de jeux de donnees de test synthetiques et valides pour un environnement de recette
- Assistant de documentation automatique d'un schema de donnees ou d'un pipeline existant
- Copilote de generation de requetes SQL a partir d'une demande en langage naturel
- Assistant de resume et de priorisation de logs applicatifs
- Pipeline d'anonymisation assistee par IA d'un jeu de donnees fictif

Livrables attendus

#	Livrable
1	Une specification courte (1 page) : cas d'usage, schema d'entree/sortie, contraintes de validation
2	Un pipeline fonctionnel (script ou notebook Python) integrant au moins un appel LLM et une etape de validation de la sortie
3	Un mecanisme de logging minimal (prompt, reponse, duree, statut) sur chaque appel
4	Un jeu de test (au moins 3 cas, dont 1 cas limite ou adverse) et les resultats obtenus
5	Une mesure indicative du cout et de la latence du pipeline sur le jeu de test
6	Un support de presentation de 10 minutes (slides ou demonstration live)

Contraintes a respecter

- Aucune donnee reelle ou de production BFORBANK ne doit etre utilisee : uniquement des donnees fictives
- Toute cle d'API doit etre geree via une variable d'environnement, jamais en dur dans le code
- Le pipeline doit inclure une etape de validation de la sortie du LLM (schema, regle metier ou controle humain)
- Le code doit rester dans le perimetre du depot Git de la formation (pas de diffusion externe)

Rappel securite et conformite
Ce projet est realise dans le cadre d'une formation BFORBANK : aucune donnee reelle, aucun systeme de production, et aucune cle d'API personnelle ou d'entreprise ne doivent y figurer. Utilisez uniquement les cles de test fournies par le formateur et des jeux de donnees fictifs.

Planning de la journee

Horaire	Sequence
9h00 - 9h20	Lancement, presentation des consignes et des cas d'usage suggeres
9h20 - 11h15	Cadrage (module 9) : choix du cas d'usage, architecture, specification technique
11h15 - 12h30	Debut d'implementation en autonomie (sur la base de la specification validee)
12h30 - 13h30	Pause dejeuner
13h30 - 15h00	Implementation du pipeline en autonomie
15h00 - 15h30	Tests, evaluation, mesure du cout et de la latence
15h30 - 15h45	Pause
15h45 - 16h30	Presentations des projets (10 min par groupe)
16h30 - 17h00	Debriefing collectif, quiz de revision, bilan de formation

Points de passage obligatoires

- Avant 11h15 : cas d'usage, architecture et specification technique valides par le formateur
- Avant 12h30 : implementation demarree sur la base de la specification validee
- Avant 15h00 : pipeline fonctionnel sur le cas nominal
- Avant 15h30 : au moins un cas limite ou un prompt adverse teste
- A 16h30 : presentation prete (support ou demonstration live)

Grille d'evaluation

Cette grille est utilisee pour un retour formatif oral a chaque groupe en fin de journee ; elle ne donne pas lieu a une notation individuelle.

Critere	Ce qui est observe
Pertinence du cas d'usage	Le cas d'usage choisi apporte une valeur claire pour un Data Engineer et le risque identifie est maitrise
Qualite de l'architecture	Les choix d'architecture (modele, orchestration, synchrone/asynchrone) sont justifies et adaptes au besoin
Robustesse du pipeline	La sortie du LLM est validee ; le pipeline gere au moins un cas limite sans echec silencieux
Securite et conformite	Aucune donnee reelle utilisee, cles API gerees correctement, logging en place
Qualite de la presentation	La demonstration est claire, tient dans le temps imparti et explicite les retours d'experience

Fiche de cadrage — a completer par le groupe

Nom du groupe / membres :

Cas d'usage retenu :

Entree / sortie du pipeline :

Principaux risques identifies et parade :